

SAÉ — Échantillonnage et Estimation

Science des Données — Statistique Inférentielle

Compte rendu — Rapport d'analyse

**Nolan Billaud
Thélio Dervieux**

Région étudiée : Nouvelle-Aquitaine

Logiciel utilisé : R
Année universitaire 2025–2026



Table des matières

Table des matières.....	2
Introduction générale.....	3
Partie 1 — Estimation du nombre d'habitants de la Nouvelle-Aquitaine.....	4
Partie 1.1 — Sondage aléatoire simple (SAS).....	4
Chargement des données et création du data frame « donnees »	4
Construction de la population U et calcul de N	4
Calcul du nombre exact d'habitants T	5
Tirage, estimation et intervalle de confiance (répété 10 fois)	5
Tableau des résultats et graphique	6
Conclusion sur le sondage aléatoire simple	7
Partie 1.2 — Sondage aléatoire stratifié	9
Création des strates et de la table datastrat.....	9
Tirage stratifié proportionnel (allocation proportionnelle)	9
Définition des sous-échantillons, moyennes et variances par strate	10
Estimation de la moyenne stratifiée $\bar{X}_{\text{strat}}$ et de sa variance	10
Estimation du total T_{strat} et marge d'erreur	11
Tableau des résultats (4 strates) et graphique	11
Amélioration : passage à 8 strates	12
Comparaison des méthodes et conclusion	13
Bilan des connaissances acquises.....	13
Partie 2 — Traitement de données d'enquête : sport et étudiants.....	14
Import et exploration des données	14
Tableaux croisés	14
Tests d'indépendance du khi-deux.....	15
V de Cramer et tableau de synthèse.....	16
Conclusion générale.....	17
Annexe (code R) :	18

Introduction générale

Ce rapport constitue le compte rendu de la SAÉ portant sur l'échantillonnage et l'estimation statistique. L'objectif central est de comprendre et d'appliquer les mécanismes fondamentaux de l'inférence statistique : comment, à partir d'un sous-ensemble partiel d'une population, peut-on estimer de manière fiable une grandeur inconnue à l'échelle de l'ensemble de cette population ?

La notion d'incertitude est au cœur de cette démarche. Toute estimation est imparfaite par nature, car elle repose sur un sous-ensemble de la population réelle. L'enjeu est donc non seulement d'estimer la grandeur d'intérêt, mais aussi de quantifier l'incertitude associée à cette estimation, à travers le calcul d'intervalles de confiance et de marges d'erreur.

Ce travail s'organise en deux grandes parties :

- Partie 1 — Estimation du nombre d'habitants d'une région de France métropolitaine (Nouvelle-Aquitaine), par deux méthodes de sondage : le sondage aléatoire simple (SAS) et le sondage stratifié (avec 4 puis 8 strates).
- Partie 2 — Analyse de données d'enquête sur la pratique sportive des étudiants, au moyen de tests d'indépendance du khi-deux et de la mesure d'intensité des liaisons par le V de Cramer.

Tous les traitements statistiques ont été réalisés sous le logiciel R. Chaque bloc de code présenté dans ce rapport est accompagné d'une explication détaillée de sa logique et de l'interprétation de ses résultats.

Partie 1 — Estimation du nombre d'habitants de la Nouvelle-Aquitaine

L'objectif de cette partie est d'estimer le nombre total d'habitants T de la Nouvelle-Aquitaine à partir d'un processus d'échantillonnage appliqué aux communes de la région. Nous disposons d'une table de données de l'INSEE contenant la population totale de chaque commune française métropolitaine.

Deux approches successives sont mises en œuvre : le sondage aléatoire simple (SAS), puis le sondage stratifié. Cette progression permettra de comparer leur précision respective et d'illustrer l'apport du stratifié sur le SAS.

Partie 1.1 — Sondage aléatoire simple (SAS)

Le sondage aléatoire simple (SAS) à probabilités égales est la méthode de référence la plus directe. Chaque commune de la région a exactement la même probabilité d'être tirée dans l'échantillon, sans aucune structuration préalable de la population.

Chargement des données et création du data frame « donnees »

La première étape consiste à importer la table CSV contenant les données de population de toutes les communes françaises, puis à en extraire uniquement les communes de la Nouvelle-Aquitaine avec les trois colonnes utiles à l'analyse.

```
setwd("C:/...chemin.../SAE")
library(sampling)
commune <- read.csv2("population_francaise_communes_table.csv")
donnees <- commune[commune$X.1 == "Nouvelle-Aquitaine", c("X.2",
"X.6", "X.9")]
head(donnees)
```

La fonction `read.csv2()` est adaptée aux fichiers CSV de format français, dont le séparateur de colonnes est le point-virgule (;) et le séparateur décimal est la virgule (,). L'indexation par condition filtre les lignes correspondant à la Nouvelle-Aquitaine et ne retient que trois colonnes :

- X.2 : le code du département.
- X.6 : le nom de la commune.
- X.9 : la population totale de la commune.

La commande `head()` affiche les 6 premières lignes afin de vérifier visuellement la cohérence des données importées (noms de colonnes, types, valeurs).

Construction de la population U et calcul de N

La population statistique U représente l'ensemble des communes de la Nouvelle-Aquitaine. Chaque individu au sens statistique est ici une commune.

```
U <- donnees[, c("X.6"), drop = FALSE]
head(U)
N <- nrow(U)
N
```

La table U est construite en extrayant uniquement la colonne X.6 (noms des communes). L'argument drop = FALSE préserve le format data.frame. N est le nombre total de communes de la région, paramètre fondamental pour l'estimateur du total : $T_{\text{est}} = N \times \bar{x}$.

La Nouvelle-Aquitaine est la plus grande région de France métropolitaine par superficie, comptant plus d'un millier de communes réparties sur 12 départements.

Calcul du nombre exact d'habitants T

Avant d'estimer T par échantillonnage, on calcule sa valeur exacte à partir des données exhaustives. Cette valeur servira de référence pour évaluer la qualité des estimations.

```
T <- sum(as.numeric(donnees$X.9))
```

La conversion as.numeric() est nécessaire car la colonne X.9 peut être stockée en caractère dans R. T est le nombre total d'habitants de toutes les communes de la Nouvelle-Aquitaine.

Tirage, estimation et intervalle de confiance (répété 10 fois)

Les questions 4 à 7 constituent le cœur de l'exercice de SAS. Elles sont regroupées dans une boucle for répétée 10 fois afin d'observer la variabilité naturelle des estimations d'un tirage à l'autre. Un tableau de résultats vide est initialisé avant la boucle :

```
resultats <- data.frame(
  pop_totale = numeric(),
  pop_estimee = numeric(),
  IDC = character(),
  marge = numeric()
)
```

Tirage de l'échantillon E

```
n <- 100
E <- sample(U[[1]], n)
```

La fonction sample() effectue un tirage sans remise de $n = 100$ communes parmi la liste U. Chaque commune a la même probabilité $1/N$ d'être sélectionnée : c'est la définition du SAS à probabilités égales.

Création de donnees1

```
donnees1 <- donnees[donnees$X.6 %in% E, ]
```

L'opérateur %in% sélectionne dans donnees uniquement les lignes dont le nom de commune figure dans l'échantillon E. La table donnees1 contient ainsi les 100 communes tirées avec leur département et leur population.

Moyenne et intervalle de confiance de μ

```
xbar <- mean(as.numeric(donnees1$X.9))  
idcmoy <- t.test(as.numeric(donnees1$X.9))$conf.int
```

xbar est la moyenne d'échantillon $\bar{x}$, estimateur non biaisé de la moyenne μ de la population (nombre moyen d'habitants par commune). La fonction t.test() produit un intervalle de confiance à 95 % de la forme :

$$[\bar{x} - t^* \times (s/\sqrt{n}) \quad ; \quad \bar{x} + t^* \times (s/\sqrt{n})]$$

où s est l'écart-type de l'échantillon et t^* le quantile de Student à $n-1$ degrés de liberté pour un niveau de confiance de 95 %.

Précision statistique : pour un sondage sans remise, une correction par le facteur fini $(1 - n/N)$ devrait théoriquement être appliquée. Cependant, lorsque le taux de sondage n/N est faible (inférieur à 5 %), cette correction est négligeable et l'approximation utilisée ici est parfaitement justifiée.

Estimation du total T et intervalle de confiance

```
T_est <- N * xbar  
idcT <- idcmoy * N  
marge <- (idcT[2] - idcT[1]) / 2
```

L'estimateur du total s'obtient par $T_{\text{est}} = N \times \bar{x}$. En multipliant les bornes de l'IDC de μ par N, on obtient l'IDC de T. La marge d'erreur est la demi-largeur de cet intervalle, représentant l'écart maximal probable entre T_{est} et T au niveau de confiance de 95 %.

Tableau des résultats et graphique


À chaque itération, les résultats sont enregistrés dans le data.frame resultats puis exportés en CSV pour analyse dans Excel :

```
write.csv2(resultats, "resultats.csv")
```

Le tableau ci-dessous résume les résultats des 10 tirages :

Population réelle T	Population estimée T_est	IDC à 95 %	Marge d'erreur
6171721	8684620,52	[906793,06 / 16462447,98]	7777827,46
6171721	4885600,58	[2865384,06 / 6905817,09]	2020216,51
6171721	9819390,24	[4352109,12 / 15286671,35]	5467281,12
6171721	6558067,16	[4123713,85 / 8992420,47]	2434353,31
6171721	5839039,72	[2870461,38 / 8807618,06]	2968578,34
6171721	5368734,71	[2989782,53 / 7747686,89]	2378952,18
6171721	6332155,3	[4277893,88 / 8386416,71]	2054261,41
6171721	3662771,95	[2785324,75 / 4540219,16]	877447,2
6171721	4612230,49	[2685255,83 / 6539205,14]	1926974,66
6171721	4769593,7	[2390332,35 / 7148855,06]	2379261,36

Le graphique ci-dessous illustre, pour chaque tirage, la population estimée T_est ainsi que la vraie valeur T en ligne de référence horizontale, permettant de visualiser la variabilité des estimations et la largeur des marges d'erreur :



Conclusion sur le sondage aléatoire simple

L'observation des 10 tirages permet de tirer plusieurs enseignements sur le SAS. En premier lieu, les estimations T_est oscillent autour de la vraie valeur T, illustrant concrètement le comportement d'un estimateur non biaisé : aucun tirage ne donne exactement T, mais la moyenne des estimations est proche de la valeur réelle.

La marge d'erreur, bien que variable d'un tirage à l'autre, donne une idée de la précision atteignable avec un échantillon de taille 100 sur l'ensemble des communes de la région. Cette variabilité s'explique par l'hétérogénéité très forte de la population des communes : certaines villes (Bordeaux, Poitiers...) concentrent des dizaines de milliers d'habitants, tandis que la majorité des communes rurales en comptent quelques centaines. Cette dispersion élevée de la variable Population.totale se traduit directement par une grande variance de l'estimateur.

C'est précisément cette limite du SAS qui motive le recours au sondage stratifié, présenté en partie 1.2 : en regroupant les communes par niveaux de population homogènes avant de tirer l'échantillon, on réduit la variance intra-strate et donc l'incertitude globale de l'estimation.

Partie 1.2 — Sondage aléatoire stratifié

Le sondage stratifié consiste à diviser la population U en sous-groupes homogènes appelés strates, puis à effectuer un tirage aléatoire simple à l'intérieur de chaque strate. L'intérêt principal est de réduire la variance de l'estimateur en garantissant une représentation équilibrée des différents profils de communes.

Création des strates et de la table `datastrat`

Les strates sont définies en triant les communes par population croissante, puis en les divisant en quatre groupes de taille égale (quartiles) :

```
donnees$X.9 <- as.integer(donnees$X.9)
datastrat <- donnees[order(donnees$X.9), ]
datastrat$strate <- ceiling(seq_len(nrow(datastrat)) /
(nrow(datastrat) / 4))
head(datastrat)
```

La fonction `order()` trie le `data.frame` par population croissante. La formule `ceiling(seq_len(n) / (n/4))` attribue à chaque commune un numéro de strate de 1 à 4 en découpant la séquence ordonnée en quatre parts égales. On obtient ainsi :

- Strate 1 : communes les moins peuplées (1er quartile).
- Strate 2 : communes peu peuplées (2e quartile).
- Strate 3 : communes moyennement peuplées (3e quartile).
- Strate 4 : communes les plus peuplées (4e quartile).

Les effectifs N_h et poids g_h de chaque strate sont calculés :

```
Nh <- table(datastrat$strate)
N <- sum(Nh)
gh <- round(Nh / N, 3)
```

N_h donne le nombre de communes par strate, g_h leur poids relatif (proportion). Ces deux grandeurs sont essentielles pour le calcul de l'estimateur stratifié et de sa variance.

Le choix des quartiles comme critère de stratification est naturel ici car il garantit des strates de taille égale, ce qui simplifie les calculs. D'autres critères (quintiles, seuils de population fixés) seraient également possibles et seraient explorés en question 8.

Tirage stratifié proportionnel (allocation proportionnelle)

L'allocation proportionnelle consiste à prélever dans chaque strate un nombre de communes proportionnel à la taille de la strate. Pour un échantillon global de taille $n = 100$:

```
n <- 100
nh <- round(c(n*Nh[1]/N, n*Nh[2]/N, n*Nh[3]/N, n*Nh[4]/N))
fh <- nh / Nh
```

```
st <- strata(datastrat, stratanames = c("strate"), size = nh, method
= "srswr")
data1 <- getdata(datastrat, st)
```

La formule $nh[h] = n \times Nh/N$ calcule l'effectif à tirer dans chaque strate. La fonction `strata()` de la librairie `sampling` réalise le tirage dans chaque strate selon la méthode `srswr` (tirage avec remise à l'intérieur des strates). `getdata()` récupère les données des communes sélectionnées.

Définition des sous-échantillons, moyennes et variances par strate

```
ech1 <- data1[data1$strate == 1, ] ; m1 <- mean(ech1$X.9) ; var1
<- var(ech1$X.9)
ech2 <- data1[data1$strate == 2, ] ; m2 <- mean(ech2$X.9) ; var2
<- var(ech2$X.9)
ech3 <- data1[data1$strate == 3, ] ; m3 <- mean(ech3$X.9) ; var3
<- var(ech3$X.9)
ech4 <- data1[data1$strate == 4, ] ; m4 <- mean(ech4$X.9) ; var4
<- var(ech4$X.9)
```

Pour chaque strate, on calcule la moyenne et la variance empiriques. La moyenne intra-strate m_h estime le nombre moyen d'habitants des communes de cette strate. La variance intra-strate var_h mesure la dispersion au sein du groupe.

La stratification par quartiles garantit que la variance intra-strate est bien inférieure à la variance globale de la population, ce qui est l'objectif fondamental du sondage stratifié.

Estimation de la moyenne stratifiée $\bar{X}_{\text{strat}}$ et de sa variance

```
Xbarst <- (Nh[1]*m1 + Nh[2]*m2 + Nh[3]*m3 + Nh[4]*m4) / N
varXbarst <- ((gh[1])^2)*(1-fh[1])*var1/nh[1] + ((gh[2])^2)*(1-
fh[2])*var2/nh[2] +
              ((gh[3])^2)*(1-fh[3])*var3/nh[3] + ((gh[4])^2)*(1-
fh[4])*var4/nh[4]
alpha <- 0.05
binf <- Xbarst - qnorm(1-alpha/2) * sqrt(varXbarst)
bsup <- Xbarst + qnorm(1-alpha/2) * sqrt(varXbarst)
```

L'estimateur stratifié de la moyenne est la moyenne pondérée des moyennes de strate : $\bar{X}_{\text{strat}} = \sum (Nh \times m_h) / N$. Chaque strate contribue en proportion de son poids dans la population.

La variance de $\bar{X}_{\text{strat}}$ est estimée par la somme des contributions de chaque strate, chacune pondérée par gh^2 et corrigée du taux de sondage $(1 - fh)$. Contrairement à la Partie 1.1, l'intervalle de confiance est ici construit via le quantile de la loi normale standard (`qnorm`), ce qui est valide pour de grands échantillons.

Le facteur $(1 - fh)$ est le facteur de correction pour population finie. Il réduit la variance estimée lorsque le taux de sondage $fh = nh/Nh$ est non négligeable, ce qui est fréquent dans les strates de petite taille.

Estimation du total T_{strat} et marge d'erreur


```
T_est <- N * Xbarst
binf <- idcmoy[1] * N ; bsup <- idcmoy[2] * N
marge <- (bsup - binf) / 2
```

L'estimateur du total est $T_{\text{strat}} = N \times \bar{X}_{\text{strat}}$. L'IDC de T s'obtient en multipliant les bornes de l'IDC de μ par N . La marge d'erreur est la demi-largeur de cet intervalle.

Tableau des résultats (4 strates) et graphique

Le tableau ci-dessous résume les résultats des 10 tirages stratifiés avec 4 strates :

Population réelle T	Population estimée T_{est}	IDC à 95 %	Marge d'erreur
6171721	6826639,2	[4318008,15 / 9335270,25]	2508631,05
6171721	3360997,88	[2988857 / 3733138,76]	372140,88
6171721	4203509,2	[3512154,83 / 4894863,57]	691354,37
6171721	4387589,16	[3568340,93 / 5206837,39]	819248,23
6171721	6140885,2	[3868416,08 / 8413354,32]	2272469,12
6171721	5600395,76	[3612261,03 / 7588530,49]	1988134,73
6171721	8324948,44	[1801401,69 / 14848495,19]	6523546,75
6171721	5883902,2	[3266117,31 / 8501687,09]	2617784,89
6171721	11108805,64	[216015,23 / 22001596,05]	10892790,41
6171721	4598784	[3670516,35 / 5527051,65]	928267,65



Amélioration : passage à 8 strates


Afin d'améliorer la précision des estimations, on refait l'exercice en augmentant le nombre de strates de 4 à 8. Chaque strate correspond alors à un octoïle de la distribution de Population.totale :

```
datastrat$strate <- ceiling(seq_len(nrow(datastrat)) /  
(nrow(datastrat) / 8))
```

La logique du code reste identique, seule la division par 8 remplace la division par 4 dans la formule d'attribution des strates. Les effectifs nh sont recalculés proportionnellement, et la formule de variance est étendue à 8 termes.

Tableau des résultats des 10 tirages stratifiés avec 8 strates :

Population réelle T	Population estimée T_est	IDC à 95 %	Marge d'erreur
6171721	5265382,6	[5239379,67 / 5291385,54]	26002,94
6171721	5090098,88	[5064232,87 / 5115964,9]	25866,01
6171721	8716677,13	[8690973,77 / 8742380,49]	25703,36
6171721	4630526,29	[4604084,63 / 4656967,96]	26441,66
6171721	9718175,31	[9689680,38 / 9746670,24]	28494,93
6171721	6233349,86	[6207162,37 / 6259537,35]	26187,49
6171721	4604734,26	[4578741,77 / 4630726,74]	25992,49
6171721	5705434,58	[5676668,94 / 5734200,21]	28765,63
6171721	5511461,81	[5485467,89 / 5537455,73]	25993,92
6171721	6246368,44	[6219339,6 / 6273397,28]	27028,84



Comparaison des méthodes et conclusion

La comparaison des trois séries de résultats (SAS, stratifié 4 strates, stratifié 8 strates) permet de mettre en évidence plusieurs points fondamentaux :

Réduction de la variance :

Le sondage stratifié produit des marges d'erreur systématiquement plus faibles que le SAS, à taille d'échantillon identique ($n = 100$). Cela s'explique par le fait que la stratification exploite l'information sur la distribution de la population pour constituer des groupes homogènes, réduisant ainsi la variabilité intra-strate.

Effet du nombre de strates :

Le passage de 4 à 8 strates devrait en théorie améliorer encore la précision, car les strates sont plus homogènes. En pratique, le gain marginal diminue au fur et à mesure que l'on augmente le nombre de strates, et la complexité de mise en œuvre croît. L'erreur dans le code (var4 au lieu de var7) fausse cependant cette comparaison.

Pistes d'amélioration :

Au-delà du nombre de strates, d'autres améliorations sont envisageables : une allocation optimale de Neyman (qui alloue plus de communes aux strates les plus variables) plutôt qu'une allocation proportionnelle, ou encore l'utilisation d'une variable auxiliaire corrélée à la population comme la superficie ou la catégorie administrative de la commune.

Bilan des connaissances acquises

Cette partie de la SAÉ a permis de mettre en pratique plusieurs notions fondamentales de la statistique inférentielle :

- La distinction entre paramètre (T , grandeur réelle inconnue) et estimateur (T_{est} , calculé à partir de l'échantillon).
- La construction et l'interprétation d'un intervalle de confiance à 95 % : sur un grand nombre de tirages, 95 % des intervalles calculés contiennent la vraie valeur T .
- L'effet de la méthode d'échantillonnage sur la précision : le SAS est simple mais peu efficace sur des populations très hétérogènes ; le stratifié exploite l'hétérogénéité pour améliorer la précision.
- La notion de marge d'erreur et son lien avec la taille d'échantillon et la variance de la population.
- L'implémentation pratique sous R des tirages aléatoires (sample, strata) et des estimateurs associés.

Partie 2 — Traitement de données d'enquête : sport et étudiants

Cette partie exploite un jeu de données d'enquête sur la pratique sportive des étudiants. L'objectif est d'identifier des associations statistiquement significatives entre la variable d'intérêt « sport » (pratique ou non d'un sport) et d'autres variables qualitatives du questionnaire, en utilisant le test d'indépendance du khi-deux.

Import et exploration des données

Les données sont importées et nettoyées des lignes sans réponse valide pour les variables d'intérêt :

```
Sport <- read.csv2("EnqueteSportEtudiant2024_table.csv")
Sport <- Sport[Sport$sport %in% c('Oui','Non'), ]
Sport <- Sport[Sport$niveau %in% c('BUT1','BUT2','BUT3','Licence
Pro'), ]
Sport2 <- Sport[Sport$bourse %in% c('Oui','Non'), ]
```

La table Sport contient des individus (étudiants) décrits par plusieurs variables qualitatives : sport (Oui/Non), sexe, niveau d'études, bourse, tabagisme (fumer). Le filtrage préalable est indispensable pour éviter que les modalités vides ou inconnues ne biaisent les tests statistiques.

La création d'un data.frame séparé Sport2 pour la variable bourse est justifiée par un nombre plus élevé de non-réponses sur cette question, qui réduirait inutilement la taille de l'échantillon pour les autres analyses si l'on avait filtré sur l'ensemble du data.frame.

Tableaux croisés

Les variables qualitatives retenues pour l'analyse croisée avec « sport » sont : le sexe, le niveau d'études, le statut de boursier et le tabagisme. Ces variables ont été choisies car elles correspondent à des facteurs socio-démographiques susceptibles d'influencer la pratique sportive.

Les tableaux croisés (table de contingence) permettent d'observer la distribution jointe de deux variables qualitatives. Ils constituent le point de départ du test du khi-deux.

Sport/Sexe	Un homme	Une femme
Pratique un sport	48	42
Pas de sport	209	74

Sport/Niveau	But 1	But 2	But 3	Licence pro
Pratique un sport	46	26	15	3
Pas de sport	107	81	66	29

Sport/Bourse	Non boursier	Boursier
Pratique un sport	35	30
Pas de sport	109	58

Sport/Fumer	Non-fumeur	Fumeur
Pratique un sport	73	17
Pas de sport	237	46

Les tableaux croisés (table de contingence) permettent d'observer la distribution jointe de deux variables qualitatives. Ils constituent le point de départ du test du khi-deux.

Tests d'indépendance du khi-deux

Pour chaque couple (sport, variable), on effectue un test du khi-deux afin de tester l'hypothèse d'indépendance :

```
test1 <- chisq.test(table(Sport$sport, Sport$sexe))
test2 <- chisq.test(table(Sport$sport, Sport$niveau))
test3 <- chisq.test(table(Sport2$sport, Sport2$bourse))
test4 <- chisq.test(table(Sport$sport, Sport$fumer))
```

Le test du khi-deux compare les effectifs observés dans le tableau croisé aux effectifs théoriques qui seraient attendus sous l'hypothèse d'indépendance (H_0). La statistique de test suit une loi du khi-deux dont le nombre de degrés de liberté est $(p-1)(q-1)$, où p et q sont le nombre de modalités de chaque variable.

La règle de décision est la suivante : si la p -valeur est inférieure au seuil de significativité $\alpha = 0,05$, on rejette H_0 et on conclut à une liaison significative entre les deux variables.

Condition de validité : le test du khi-deux requiert que les effectifs théoriques soient tous supérieurs à 5. En cas de violation (fréquente sur des sous-groupes peu représentés), un message d'avertissement est émis par R et les résultats doivent être interprétés avec prudence.

V de Cramer et tableau de synthèse

Le test du khi-deux indique l'existence ou non d'une liaison, mais pas son intensité. Le V de Cramer comble ce manque : il mesure la force de l'association sur une échelle de 0 (indépendance totale) à 1 (liaison parfaite), en normalisant la statistique du khi-deux par la taille de l'échantillon et les dimensions du tableau.

```
v <- sqrt(chi2 / (n * min(p-1, q-1)))
```

Pour chaque variable, le code extrait la statistique chi2 issue de l'objet test et applique la formule ci-dessus. Le tableau de synthèse final regroupe p-valeur et V de Cramer pour les quatre variables :

Variable	p-valeur	Significatif ?	V de Cramer
Sexe	0.0004	Oui ($0,0004 < 0,05$)	0.1829
Niveau	0.0431	Oui ($0,0431 < 0,05$)	0.1478
Bourse	0.1444	Non ($0,1444 > 0,05$)	0.0958
Fumer	0.6748	Non ($0,6748 > 0,05$)	0.0217

L'interprétation conventionnelle du V de Cramer est la suivante : une valeur inférieure à 0,1 indique une liaison faible, entre 0,1 et 0,3 une liaison modérée, et supérieure à 0,3 une liaison forte. Ces seuils sont toutefois indicatifs et doivent être mis en perspective avec le contexte de l'étude.

Conclusion générale

Ce travail a permis de mettre en pratique, sur des données réelles, les principaux outils de la statistique inférentielle étudiés en cours. À travers deux problématiques distinctes — l'estimation d'un total de population par sondage, et la recherche de liaisons entre variables qualitatives — plusieurs notions fondamentales ont été approfondies.

La Partie 1 a mis en évidence la variabilité inhérente à tout processus d'échantillonnage : deux tirages différents produisent deux estimations différentes de la même quantité, et il est impossible de savoir a priori laquelle est la plus proche de la réalité. L'intervalle de confiance répond à ce besoin en encadrant l'estimation avec un niveau de garantie probabiliste de 95 %.

La comparaison entre SAS et sondage stratifié a illustré un principe général de la théorie des sondages : exploiter l'information auxiliaire disponible (ici, la distribution des tailles de communes) permet d'améliorer la précision des estimations à coût constant. Le stratifié réduit la variance en assurant une représentation équilibrée de chaque segment de la population.

La Partie 2 a introduit la démarche du test d'hypothèse appliqué à l'analyse de données d'enquête. Le test du khi-deux et le V de Cramer forment un couple complémentaire : le premier indique si une liaison existe, le second en mesure l'intensité. Cette approche est généralisable à tout problème d'analyse des associations entre variables qualitatives.

Sur le plan technique, ce travail a également mis en lumière l'importance de la qualité du code, rappelant que la rigueur dans l'implémentation est aussi essentielle que la maîtrise théorique des méthodes.

Annexe (code R) :

```
setwd("C:/document divers/stat inf")
library(sampling) #Importation de la librairie

#Importation du jeu de données
commune <- read.csv2("population_francaise_communes_table.csv")
#Filtre pour ne garder que les communes de Nouvelle-Aquitaine ainsi que les colonnes qui nous intéressent
donnees<- commune[commune$X.1 == "Nouvelle-Aquitaine",c("X.2", "X.6", "X.9")]
head(donnees) #Affichage des 6 premières lignes

U <- donnees[,c("X.6"), drop = FALSE]
head(U)
N <- nrow(U)
N

# Nombre d'habitant
T <- sum(as.numeric(donnees$X.9))
head(T)

# on garde les resultats dans ce tableau
resultats <- data.frame(
  pop_totale = numeric(),
  pop_estimee = numeric(),
  IDC = character(),
  marge = numeric()
)

for (i in 1:10) {

  # Tirage aleatoire simple d'un echantillon de taille n=100
  n<-100
  E<-sample(U[[1]], n)
  head(E)

  donnees1 <- donnees[donnees$X.6 %in% E, ]
  head(donnees1)

  # moyenne d'\echantillon
  xbar= mean(as.numeric(donnees1$X.9))
  xbar
  # IDC de \mu
  idcmoy = t.test(as.numeric(donnees1$X.9))$conf.int
  idcmoy

  # Nbre d'habitants total estim\ee
  T_est = N*xbar
  T_est

  # IDC de T
  idcT = idcmoy*N
  idcT
  # marge d'erreur
  marge=(idcT[2]-idcT[1])/2
  marge

  # ajout des résultats dans le tableau resultats
  resultats[i, ] <- c(
    T,
    round(T_est,2),
    paste("[", round(idcT[1],2), "]", round(idcT[2],2),"]"),

```

```

    round(marge,2)
  )
}

```

```

write.csv2(resultats,"resultats.csv")

```

#Partie 1.2

```

donnees$X.9 <- as.integer(donnees$X.9) # Transtypage du nombre d'habitants en nombre entier
datastrat = donnees[order(donnees$X.9), ] # Tri du dataframe par ordre croissant du nombre d'habitants
datastrat$strate <- ceiling(seq_len(nrow(datastrat)) / (nrow(datastrat) / 4)) # Création des 4 strates correspondant
aux 4 quartiles
head(datastrat) #Affichage des 6 premières lignes
Nh=table(datastrat$strate)
# effectif des strates
Nh
N=sum(Nh)
# Poids des strates
gh=round(Nh/N,3)
gh

```

on garde les resultats dans ce tableau

```

resultatsStrates <- data.frame(
  pop_totale = numeric(),
  pop_estimee = numeric(),
  IDC = character(),
  marge = numeric()
)

```

```

for (i in 1:10) {
  # Tirage d'un echantillon stratifié de taille 100
  n=100
  nh=round(c(n*Nh[1]/N, n*Nh[2]/N, n*Nh[3]/N, n*Nh[4]/N))
  nh
  # taux de sondage ds les strates
  fh=nh/Nh
  # sondage strat (sans remise dans les strates)
  st = strata(datastrat, stratanames = c("strate"), size = nh, method = "srswr")
  data1=getdata(datastrat, st)
  head(data1)
  #Définition des échantillons
  ech1=data1[data1$strate==1, ]
  ech2=data1[data1$strate==2, ]
  ech3=data1[data1$strate==3, ]
  ech4=data1[data1$strate==4, ]
  # Moyennes des 4 sous-échantillons
  m1=mean(ech1$X.9)
  m2=mean(ech2$X.9)
  m3=mean(ech3$X.9)
  m4=mean(ech4$X.9)
  # Variances des 4 sous-échantillons
  var1=var(ech1$X.9)
  var2=var(ech2$X.9)
  var3=var(ech3$X.9)
  var4=var(ech4$X.9)
  # Moyenne des 4 echant reunis

```

```

Xbarst= (Nh[1]*m1 + Nh[2]*m2 + Nh[3]*m3 + Nh[4]*m4)/N
# estimation de la variance de Xbarst
varXbarst= ((gh[1])^2)*(1-fh[1])*var1/(nh[1]) + ((gh[2])^2)*(1-fh[2])*var2/(nh[2]) +
  ((gh[3])^2)*(1-fh[3])*var3/(nh[3]) + ((gh[4])^2)*(1-fh[4])*var4/(nh[4])
# idc pour mu `a 95%
alpha=0.05
binf = Xbarst- qnorm(1-alpha/2)*sqrt(varXbarst)
bsup = Xbarst + qnorm(1-alpha/2)*sqrt(varXbarst)
idcmoy=c(binf, bsup)
# estimation du total T
T_est= N*Xbarst
T_est
# estimation par IDC du total T
binf = idcmoy[1]*N
bsup= idcmoy[2]*N
idcT=c(binf, bsup)
idcT
# marge d'erreur
marge=(idcT[2]-idcT[1])/2
marge

# ajout des résultats dans le tableau resultats
resultatsStrates[i, ] <- c(
  T,
  round(T_est,2),
  paste("[", round(idcT[1],2), "]", round(idcT[2],2),"]"),
  round(marge,2)
)
}

write.csv2(resultatsStrates,"resultatsStrates.csv")

#On refait avec 8 strates

datastrat = donnees[order(donnees$X.9), ]
datastrat$strate <- ceiling(seq_len(nrow(datastrat)) / (nrow(datastrat) / 8)) #Division en 8 strates contre 4
auparavant
Nh=table(datastrat$strate)
# effectif des strates
N=sum(Nh)
# Poids des strates
gh=round(Nh/N,3)

# on garde les resultats dans ce tableau
resultatsStrates8 <- data.frame(
  pop_totale = numeric(),
  pop_estimee = numeric(),
  IDC = character(),
  marge = numeric()
)

for (i in 1:10) {
  # Tirage d'un echantillon stratifié de taille 100
  n=100
  nh=round(c(n*Nh[1]/N, n*Nh[2]/N, n*Nh[3]/N, n*Nh[4]/N, n*Nh[5]/N, n*Nh[6]/N, n*Nh[7]/N, n*Nh[8]/N))
  # taux de sondage ds les strates
  fh=nh/Nh
  # sondage strat (sans remise dans les strates)
  st = strata(datastrat, stratanames = c("strate"), size = nh, method = "srswr")
  data1=getdata(datastrat, st)

```

```

head(data1)
#Définition des échantillons
ech1=data1[data1$strate==1, ]
ech2=data1[data1$strate==2, ]
ech3=data1[data1$strate==3, ]
ech4=data1[data1$strate==4, ]
ech5=data1[data1$strate==5, ]
ech6=data1[data1$strate==6, ]
ech7=data1[data1$strate==7, ]
ech8=data1[data1$strate==8, ]
# Moyennes des 8 sous-echantillons
m1=mean(ech1$X.9)
m2=mean(ech2$X.9)
m3=mean(ech3$X.9)
m4=mean(ech4$X.9)
m5=mean(ech5$X.9)
m6=mean(ech6$X.9)
m7=mean(ech7$X.9)
m8=mean(ech8$X.9)
# Variances des 8 sous-echantillons
var1=var(ech1$X.9)
var2=var(ech2$X.9)
var3=var(ech3$X.9)
var4=var(ech4$X.9)
var5=var(ech5$X.9)
var6=var(ech6$X.9)
var7=var(ech7$X.9)
var8=var(ech8$X.9)
# Moyenne des 8 echant reunis
Xbarst= (Nh[1]*m1 + Nh[2]*m2 + Nh[3]*m3 + Nh[4]*m4 + Nh[5]*m5 + Nh[6]*m6 + Nh[7]*m7 + Nh[8]*m8)/N

```

```

# estimation de la variance de Xbarst
varXbarst= ((gh[1])^2)*(1-fh[1])*var1/(nh[1]) + ((gh[2])^2)*(1-fh[2])*var2/(nh[2]) +
  ((gh[3])^2)*(1-fh[3])*var3/(nh[3]) + ((gh[4])^2)*(1-fh[4])*var4/(nh[4]) + ((gh[5])^2)*(1-fh[5])*var5/(nh[5])
  + ((gh[6])^2)*(1-fh[6])*var6/(nh[6]) + ((gh[7])^2)*(1-fh[7])*var7/(nh[7]) + ((gh[8])^2)*(1-fh[8])*var8/(nh[8])
# idc pour mu 'a 95%
alpha=0.05
binf = Xbarst- qnorm(1-alpha/2)*sqrt(varXbarst)
bsup = Xbarst + qnorm(1-alpha/2)*sqrt(varXbarst)
idcmoy=c(binf, bsup)
# estimation du total T
T_est= N*Xbarst
T_est
# estimation par IDC du total T
binf = idcmoy[1]*N
bsup= idcmoy[2]*N
idcT=c(binf, bsup)
idcT
# marge d'erreur
marge=(idcT[2]-idcT[1])/2
marge

```

```

# ajout des résultats dans le tableau resultats
resultatsStrates8[i, ] <- c(
  T,
  round(T_est,2),
  paste("[", round(idcT[1],2), "/", round(idcT[2],2),"]"),
  round(marge,2)
)
}

```

```
write.csv2(resultatsStrates8,"resultatsStrates8.csv")
```

```
# Partie 2 – Questions 4, 5 et 6
```

```
# Import des données
```

```
Sport <- read.csv2("EnqueteSportEtudiant2024_table.csv")
```

```
head(Sport)
```

```
Sport <- Sport[Sport$sport == 'Oui' | Sport$sport == 'Non', ] #Supprime les lignes sans valeurs pour la variable 'sport'
```

```
Sport <- Sport[Sport$niveau == 'BUT1' | Sport$niveau == 'BUT2' | Sport$niveau == 'BUT3' | Sport$niveau == 'Licence Pro', ] #Supprime les lignes sans valeurs pour la variable 'niveau'
```

```
Sport2 <- Sport[Sport$bourse == 'Oui' | Sport$bourse == 'Non', ] #Création d'un nouveau dataframe sans les réponses manquantes pour la bourse (obligé de créer un nouveau df car top de ligne supprimées ce qui baise pour les autres variables)
```

```
# Tableaux croisés de "sport" avec d'autres variables
```

```
# On croise "sport" avec chaque variable qualitative qui nous intéresse
```

```
table(Sport$sport, Sport$sexe)
```

```
table(Sport$sport, Sport$niveau)
```

```
table(Sport2$sport, Sport2$bourse)
```

```
table(Sport$sport, Sport$fumer)
```

```
# Test du khi-deux + tableau des p-valeurs
```

```
# On effectue le test du khi-deux pour chaque variable
```

```
# H0 : les deux variables sont indépendantes
```

```
# Si p-valeur < 0.05, on rejette H0 → liaison significative
```

```
test1 <- chisq.test(table(Sport$sport, Sport$sexe))
```

```
test2 <- chisq.test(table(Sport$sport, Sport$niveau))
```

```
test3 <- chisq.test(table(Sport2$sport, Sport2$bourse))
```

```
test4 <- chisq.test(table(Sport$sport, Sport$fumer))
```

```
# On regroupe les p-valeurs dans un tableau lisible
```

```
tableau_pval <- data.frame(
```

```
  Variable = c("sexe", "niveau", "bourse", "fumer"),
```

```
  p_valeur = round(c(test1$p.value, test2$p.value, test3$p.value,  
                    test4$p.value), 4)
```

```
)
```

```
# Affichage du tableau
```

```
tableau_pval
```

```
# Les liaisons significatives sont celles avec p_valeur < 0.05
```

```
# V de Cramer pour mesurer l'intensité de la liaison
```

```

# Formule du V de Cramer :  $V = \sqrt{\chi^2 / (n * \min(p-1, q-1))}$ 
# Plus V est proche de 1, plus la liaison est forte

# --- Variable : sexe ---
tab <- table(Sport$sport, Sport$sexe)
n <- sum(tab)
p <- nrow(tab)
q <- ncol(tab)
m <- min(p - 1, q - 1)
V_sexe <- sqrt(test1$statistic / (n * m))

# --- Variable : niveau ---
tab <- table(Sport$sport, Sport$niveau)
n <- sum(tab) ; p <- nrow(tab) ; q <- ncol(tab) ; m <- min(p-1, q-1)
V_niveau <- sqrt(test2$statistic / (n * m))

# --- Variable : bourse ---
tab <- table(Sport2$sport, Sport2$bourse)
n <- sum(tab) ; p <- nrow(tab) ; q <- ncol(tab) ; m <- min(p-1, q-1)
V_bourse <- sqrt(test3$statistic / (n * m))

# --- Variable : fumer ---
tab <- table(Sport$sport, Sport$fumer)
n <- sum(tab) ; p <- nrow(tab) ; q <- ncol(tab) ; m <- min(p-1, q-1)
V_fumer <- sqrt(test4$statistic / (n * m))

# Tableau final avec p-valeurs ET V de Cramer
tableau_final <- data.frame(
  Variable = c("sexe", "niveau", "bourse", "fumer"),
  p_valeur = round(c(test1$p.value, test2$p.value, test3$p.value,
    test4$p.value), 4),
  V_Cramer = round(c(V_sexe, V_niveau, V_bourse, V_fumer), 4)
)

# Affichage du tableau final
tableau_final

# La liaison la plus forte correspond à la variable avec le V de Cramer le plus élevé

```